

— INDUSTRIAL PREDICTIVE QUALITY

De los datos de planta a decisiones priorizadas

Detección visual de defectos, scoring de riesgo y alertas de desviación del proceso con los datos que la planta ya genera.

Visión industrial

Sensores y SCADA

Aprendizaje autosupervisado

Despliegue local



Inspección visual

Heatmaps y ranking por pieza



Riesgo de máquina

Señales físicas y contexto



Desviación de proceso

Evolución esperada vs
observada



Priorización

Pieza → ciclo → lote → línea



— EL PROBLEMA

Las señales aparecen antes que el coste

El reto no es generar más datos ni más alarmas. Es detectar qué cambio importa, dónde aparece y qué merece atención primero.

01 · SEÑALES

**Cámaras, vibración,
corriente, SCADA y test logs**

Información rica, dispersa y con
escalas temporales distintas.



02 · COSTE OCULTO

**Defectos tardíos, scrap,
microparadas y
mantenimiento reactivo**

El impacto aparece cuando la ventana
de actuación ya es pequeña.



03 · DECISIÓN

**Una lista priorizada,
explicable y medible**

Qué inspeccionar, qué activo revisar y
cuándo se inició la desviación.

Tres módulos, un mismo sistema de decisión

01 • VISIÓN



Calidad visual

Aprende el aspecto normal de la producción y localiza desviaciones sobre la pieza.

- Heatmaps por defecto
- Ranking de inspección
- Superficie, PCB, envase o producto

02 • SENSOR



Riesgo de máquina

Combina señales físicas, variables de proceso y modelos calibrados.

- Top de activos/ciclos
- Lead time y falsas alarmas
- Features engineered + señal aprendida

03 • PROCESO



Desviación temporal

Compara la evolución esperada del proceso con la evolución realmente observada.

- Sorpresa local y persistencia
- Cambio por ventana o ciclo
- Agregación a lote y línea

Del dato bruto a una alerta accionable

El sistema combina baselines industriales fuertes con representación autosupervisada. La complejidad solo se conserva cuando aporta valor medible.



Inspección visual que puede empezar con imágenes normales



Dense features + memoria de normalidad

DINOv2/ResNet extraen descriptores locales. PatchCore y PaDiM comparan cada región con el histórico normal para localizar desviaciones.

- ✓ Score por imagen o pieza
- ✓ Mapa de calor a nivel de patch
- ✓ Umbral calibrado con producción normal
- ✓ Ranking para reducir inspección manual

Visual inspection queue



Pieza #A-1842	0.94
Pieza #A-1837	0.81
Pieza #A-1819	0.62
Pieza #A-1811	0.38

Salida del piloto: ranking, heatmap y comparación con referencias normales.

Una señal aprendida que **complementa** la ingeniería de proceso

El estándar práctico sigue siendo contexto operativo + features físicas. El modelo token-level añade información temporal cuando demuestra un delta real.

0.6609

Metadata-only

AUPRC del baseline contextual en el diagnóstico actual.

0.6766

Metadata + EWMA surprise

La sorpresa temporal añade una señal pequeña pero positiva.

0.6960

Metadata + token world model

Mejor combinación no-action; Δ AUPRC +0.0352.

Aprender el proceso normal sin esperar a acumular defectos

0

Etiquetas de defecto necesarias para iniciar el aprendizaje de normalidad

Aplicable a representación visual, anomalía y desviación temporal.

1

Los datos no etiquetados sí tienen valor

Imágenes normales, secuencias de sensores y ciclos de proceso sirven para aprender estructura y evolución esperada.

2

Las etiquetas mejoran la medición, no son un requisito universal

Defectos, scrap o fallos históricos permiten cuantificar recall, lead time y calibración cuando existen.

3

Dos salidas posibles

Sin etiquetas: anomalía y desviación. Con eventos históricos: riesgo supervisado y validación económica.

Resultados que justifican validar en datos reales

1.00

AUPRC visual

DINOv2 + PatchCore/PaDiM en un quick run de MVTec bottle.

+0.0352

Delta sensor

Token world model sobre metadata-only en el diagnóstico actual.

4-6

Semanas

Para auditar, comparar, modelar y entregar una recomendación go/no-go.

Qué sí demuestra

La arquitectura visual genera señal fuerte en un benchmark público y el modelo sensor denso añade información temporal incremental.

Qué no asumimos

Un resultado público no garantiza rendimiento en otra línea. El valor se confirma con distribución, defectos y condiciones reales del proceso del cliente.

— PILOTO

Un proceso corto para llegar a una **decisión de inversión**

SEMANA 1

Mapa de datos

Inventario, calidad, trazabilidad, temporalidad y definición del caso de uso.

SEMANAS 1-2

Baselines

Reglas, modelos clásicos y visual foundation para establecer una referencia realista.

SEMANAS 2-5

Modelado

Heatmaps, risk scoring, sorpresa temporal, calibración y análisis de errores.

SEMANA 6

Decisión

Demo local, benchmark final, impacto esperado y roadmap de integración.

— ENTREGABLES

Una demostración que el equipo puede ver, medir y discutir

- ✓ Manifest y auditoría de calidad de datos.
- ✓ Benchmark frente a reglas y baselines fuertes.
- ✓ Heatmaps y ranking de inspección visual.
- ✓ Riesgo por activo/ciclo y curvas de desviación temporal.
- ✓ Métricas operativas: precision@top-k, falsas alarmas y lead time.
- ✓ Demo local, informe ejecutivo y documentación técnica.
- ✓ Recomendación go/no-go y arquitectura de integración.

Top operational alerts

local demo

Línea 2 · Lote 184		High
Máquina 04 · Ciclo 912		High
Pieza B-3381		Review
Turno N · Proceso 7		Watch

Empezamos con lo disponible; las etiquetas son opcionales

MÍNIMO PARA EMPEZAR

- Imágenes normales o series temporales de proceso.
- Timestamp, identificador de pieza/activo/ciclo y orden temporal.
- Contexto operativo disponible: receta, material, setpoints o máquina.
- Un responsable técnico para interpretar el proceso y sus límites.

AUMENTA EL VALOR, PERO NO BLOQUEA EL PILOTO

- Defectos etiquetados o resultados de inspección.
- Fallos, scrap, retrabajo o mantenimiento histórico.
- Coste de falsa alarma y coste de defecto no detectado.
- Comandos temporales verificados para evaluar acción-condicionada.

La autosupervisión permite aprender normalidad sin etiquetas. Los eventos históricos se utilizan cuando se quiere medir o calibrar un objetivo supervisado concreto.

El piloto termina con una respuesta **cuantitativa**



Menos inspección innecesaria

Concentrar la revisión manual en las piezas o ciclos de mayor riesgo.



Más anticipación

Detectar la desviación antes del defecto, la parada o el mantenimiento reactivo.



Go / no-go defendible

Decidir si integrar, ampliar datos o descartar el caso sin depender de promesas de caja negra.

Una plataforma de validación industrial: baseline fuerte, IA donde aporta y resultados trazables.